Universidad del Valle de Guatemala
Facultad de Ingeniería
Ciencia de Datos (CC3084)



Proyecto 2 — Análisis Exploratorio
Detección de pases en video de la Bundesliga (Reto 21)

Nicolás Concuá — 23197
Felipe Aguilar — 23195
Fernando Rueda — 23748
Fernando Hernández - 23645

Guatemala, 11 de septiembre de 2026

Introducción

Este informe presenta el análisis exploratorio de datos del Reto 21: la detección de pases en videos de jugadas de fútbol de la Bundesliga mediante visión por computadora. Se trabaja con 200 clips de video de transmisión y con las anotaciones de eventos de la competencia DFL – Bundesliga Data Shootout. El objetivo del entregable es caracterizar los datos y evaluar la viabilidad de detectar pases, como paso previo al modelo de detección.

Repositorio: https://github.com/nicoCT04/Proyecto2-DataScience

1. Situación problemática

El análisis del rendimiento en el fútbol profesional depende cada vez más de datos extraídos del video: posesión, redes de pase o presión se calculan a partir de eventos como los pases. Hoy esos eventos se anotan en gran parte a mano, lo que es lento, costoso y propenso a errores. La magnitud se ve en los propios datos del reto: cada tiempo de juego anotado en `train.csv` contiene en promedio **289 pases** (entre 219 y 422), además de disputas y saques de banda, y la mediana entre pases consecutivos es de apenas **4.1 segundos**. Automatizar la detección de pases a partir del video de transmisión permitiría generar estas estadísticas a escala y para ligas sin presupuesto de anotación, pero el video presenta dificultades: cámara en movimiento y con cambios de plano, jugadores que se ocultan entre sí, un balón pequeño y rápido, y gráficos superpuestos como marcas de agua y el marcador.

1.1 Investigación del tema

Un **pase** es el envío intencional del balón de un jugador a un compañero. Detectarlo en video no es un problema de una sola imagen: es un patrón **espacio-temporal** (el balón sale de un jugador, viaja y llega a otro), por lo que se aborda como action spotting, es decir, localizar en el tiempo el instante en que ocurre una acción. La competencia DFL – Bundesliga Data Shootout plantea exactamente eso para tres eventos (jugada/pase, disputa y saque de banda) y evalúa la precisión de la predicción dentro de ventanas de tolerancia temporal. Las técnicas habituales, que orientan qué buscar en este análisis, son:

- **Muestreo de frames** a una tasa fija y **filtrado de tomas** no útiles (repeticiones, primeros planos), típicamente por la proporción de cancha visible.
- **Detección de objetos** (jugadores y balón) con redes preentrenadas como YOLO y **seguimiento** (tracking) de las detecciones entre frames.
- **Asignación de equipo** por el color de la camiseta mediante agrupamiento (k-means).
- **Señales de movimiento** entre frames (diferencia de frames o flujo óptico) para captar la dinámica del balón.
- **Modelos temporales** (CNN 3D, redes recurrentes o transformers de video) que clasifican una ventana de frames como pase o no pase, como en el benchmark SoccerNet.

Por eso el análisis exploratorio se centra en cuatro preguntas: cómo son los videos, cuánto de cada frame es cancha útil, si los jugadores y equipos pueden detectarse con herramientas estándar y cómo se distribuyen los pases en el tiempo.

2. Problema científico

¿Es posible detectar automáticamente los pases en clips de video de partidos de la Bundesliga a partir de sus características visuales (frames, jugadores, balón y movimiento), y qué propiedades de los datos condicionan esa detección? Como paso previo, este trabajo responde qué contienen los datos y qué señales visuales están disponibles para una futura detección de pases.

3. Objetivos

Objetivo general. Realizar un análisis exploratorio de los clips de video de la Bundesliga y de sus anotaciones, para caracterizar los datos y evaluar la viabilidad de detectar pases mediante visión por computadora.

Objetivos específicos:

- Verificar el formato del 100 % de los clips (200 videos de 20 partidos): resolución, fps, duración y tamaño, reportando cuántos son legibles y cuántos se desvían del formato dominante.
- Cuantificar la taxonomía y la distribución temporal de los eventos de `train.csv`: frecuencia y proporción de cada tipo de evento y de cada combinación acción × contexto, y la mediana de segundos entre pases consecutivos.
- Medir señales visuales en al menos 2,000 frames (10 por clip) —cobertura de cancha, brillo, contraste, bordes y movimiento— y reportar su estadística descriptiva, outliers (regla IQR) y correlaciones de Pearson.
- Evaluar la detección de jugadores y la separación de equipos en 600 frames con YOLOv8: jugadores promedio por frame y calidad del agrupamiento por color de camiseta medida con el coeficiente silhouette por partido.

4. Descripción de los datos

4.1 Fuentes y observaciones

La fuente es el dataset `dbal0503/Bundesliga` (Hugging Face), derivado de la competencia DFL – Bundesliga Data Shootout. Se usan dos conjuntos:

- **200 clips de video** (20 partidos, 10 clips cada uno) con formato totalmente homogéneo: 1920×1080, 25 fps y 30 segundos por clip (≈750 frames), 3.8 GB en total. Es la fuente principal del análisis visual.
- **train.csv:** 11,218 anotaciones de eventos de 12 videos (tiempos de juego de ≈47 minutos) de 8 partidos. Sus identificadores no coinciden con ninguno de los 20 partidos de los clips, por lo que se usa como contexto de la estructura del problema y no como etiquetas.

De los clips se derivaron tres tablas: `frame_features.csv` (2,000 frames × 12 variables), `player_detections.csv` (600 frames) y `jersey_colors.csv` (7,168 jugadores detectados). La Tabla 1 resume las variables; el detalle completo está en `codebook.md` del repositorio.



Figura 1. *Frame de muestra de un clip: cámara táctica, equipos separables por color, marca de agua y caja del marcador.*

Tabla 1. *Variables disponibles por conjunto de datos.*

Conjunto (obs.)	Variable	Tipo	Descripción / valores
Inventario (200 clips)	match_id, clip_idx	Categórica	20 partidos × 10 clips
	width, height, fps	Cuant. discreta	1920×1080 a 25 fps (constantes)
	duration_s, size_mb	Cuant. continua	30 s; 14.9–26.3 MB
train.csv (11,218)	video_id	Categórica	12 videos de 8 partidos
	time	Cuant. continua	Segundo del evento
	event	Categórica	play, start, end, challenge, throwin
	event_attributes	Texto (lista)	Acción y contexto (play), resultado (challenge)
frame_features (2,000)	brightness, contrast	Cuant. continua	Media y desv. estándar de gris (0–255)
	saturation	Cuant. continua	Media del canal S de HSV
	green_ratio	Cuant. continua	Proporción de píxeles de césped (0–1)
	edge_density	Cuant. continua	Proporción de bordes Canny (0–1)
	motion	Cuant. continua	Diferencia media con el frame muestreado anterior
	player_count	Cuant. discreta	Conteo de blobs (proxy clásico)
player_detections (600)	player_count	Cuant. discreta	Personas detectadas por YOLOv8n
jersey_colors (7,168)	hue, sat, val	Cuant. continua	Color HSV medio del torso

4.2 Limpieza y preprocesamiento

- **Integridad de los clips:** 200/200 descargados y legibles con ffprobe, sin duplicados ni metadatos faltantes. Duración entre 30.00 y 30.04 s; solo varía el tamaño (Figura 2).
- **Muestreo de frames:** de cada clip se toman 10 frames equiespaciados entre el 5 % y el 95 % de su duración (uno cada ≈3 s) para evitar los cortes de inicio y fin. Los frames se leen al vuelo y no se almacenan.
- **Extracción de variables:** conversión a gris y HSV; máscara de césped (H 35–90, S ≥ 40, V ≥ 40), bordes Canny y diferencia absoluta entre frames muestreados consecutivos.
- **Faltantes en train.csv:** `event_attributes` está vacío en 6,836 filas, que son exactamente los eventos `start` y `end` (3,418 × 2), que por definición no llevan atributos. Es un faltante

estructural y no se imputa. La columna de texto se convierte a lista y se separa en acción y contexto.

- **Faltantes en motion:** vale 0 en el primer frame de cada clip (200 frames) porque no hay frame previo con el cual compararlo. Ese 0 no es una medición, así que se reemplaza por un valor faltante y se excluye de las estadísticas (quedan 1,800 frames válidos).
- **Variable descartada:** el conteo de jugadores por blobs no concuerda con YOLOv8 en los mismos frames (r = −0.04; sección 5.4) y se reemplaza por el conteo de YOLO.
- **Outliers:** se identifican con la regla 1.5 × IQR pero no se eliminan (sección 5.1).

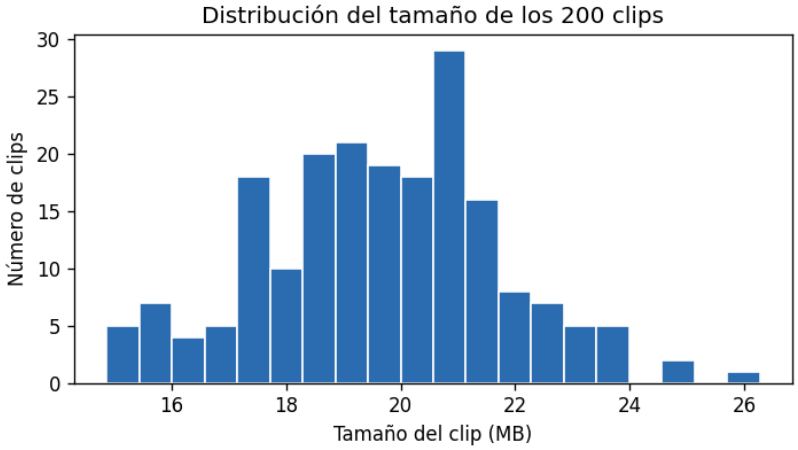


Figura 2. *Distribución del tamaño de los 200 clips.*

5. Análisis exploratorio

5.1 Variables cuantitativas visuales

Tabla 2. *Estadística descriptiva de las variables visuales (motion sin los 200 ceros estructurales).*

Variable	n	Media	Desv.	Mín.	Q1	Mediana	Q3	Máx.	Asim.
brightness	2000	104.7	14.8	64.5	98.9	106.5	113.1	153.1	-0.31
contrast	2000	45.4	6.5	27.8	40.7	45.8	49.7	69.7	0.23
saturation	2000	100.3	16.9	59.8	87.0	99.8	112.0	147.5	0.17
green_ratio	2000	0.604	0.122	0.129	0.515	0.612	0.691	0.913	-0.14
edge_density	2000	0.068	0.019	0.024	0.055	0.067	0.081	0.134	0.20
motion	1800	24.1	7.0	4.1	19.6	23.7	28.1	57.6	0.53
player_count	2000	63.4	23.7	15.0	48.0	60.0	74.0	199.0	1.35

La Tabla 2 resume las variables de los 2,000 frames. La cobertura de cancha (`green_ratio`) es alta, con mediana 0.61, porque la cámara táctica enmarca el campo; su cola hacia valores bajos (mínimo 0.13) corresponde a primeros planos, repeticiones y tomas de gradas. El brillo tiene asimetría negativa (frames oscuros) y `motion` una cola a la derecha por los cambios de plano. El conteo por blobs es la variable más asimétrica (1.35) y con un máximo de 199 personas, imposible en una cancha: es una medida ruidosa.

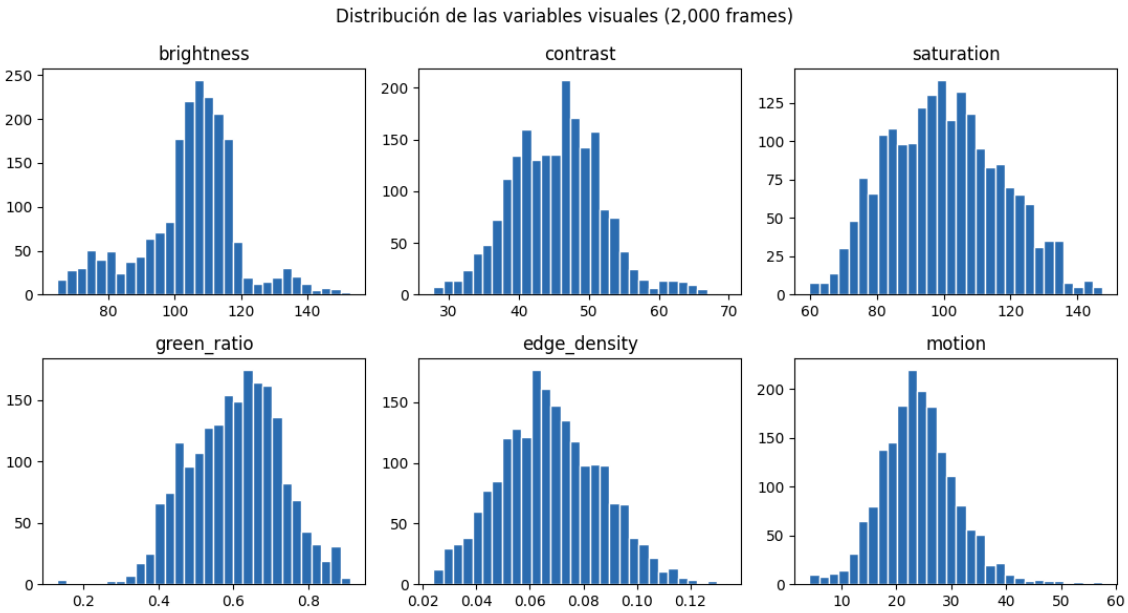


Figura 3. *Histogramas de las variables visuales.*

Tabla 3. *Outliers por la regla 1.5 × IQR.*

Variable	Bajos	Altos	% del total
brightness	136	63	10.0 %
contrast	0	21	1.1 %
saturation	0	0	0.0 %
green_ratio	5	0	0.2 %
edge_density	0	6	0.3 %
motion	13	29	2.3 %
player_count	0	76	3.8 %

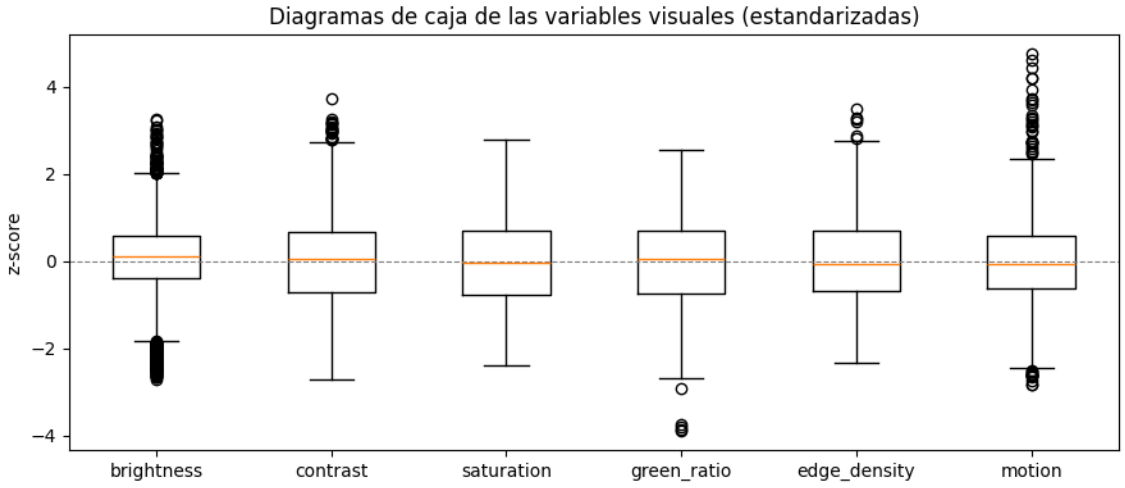


Figura 4. *Diagramas de caja de las variables visuales estandarizadas (z-score) para compararlas en un mismo eje.*

Por la regla IQR (Tabla 3), `brightness` es la variable con más outliers (199, el 10 %, en su mayoría frames oscuros) y `player_count` acumula 76 valores altos por el ruido de los blobs.

Para entender los frames con poca cancha se compararon los 100 frames por debajo del percentil 5 de `green_ratio` (< 0.41) con el resto: son **mucho más oscuros** (brillo 79 frente a 106), con **más contraste** (49.4 frente a 45.2), menos saturación y ligeramente más bordes, lo que coincide con tomas cerradas y repeticiones.

Decisión sobre outliers: no se eliminan. Son tomas reales del video y marcan justamente los momentos en que no es posible ver un pase; en la fase de modelado conviene filtrarlos con un umbral de `green_ratio` en vez de borrarlos del análisis.

5.2 Correlaciones entre variables

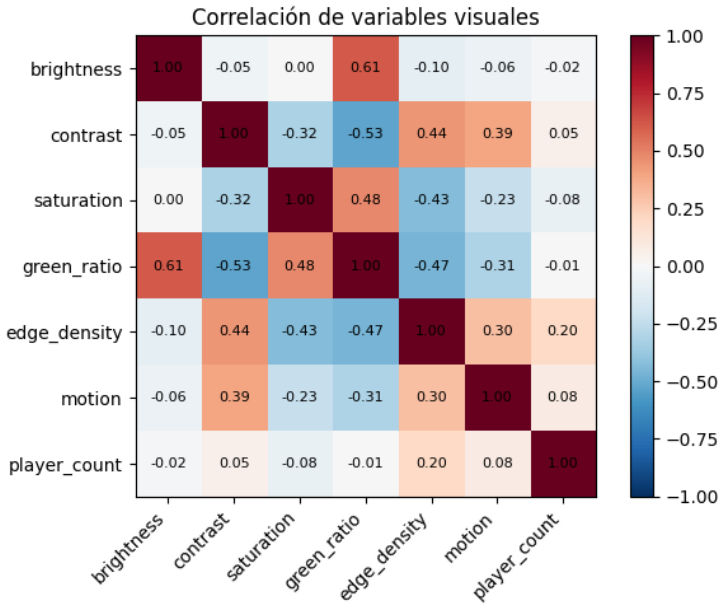


Figura 5. *Matriz de correlación de Pearson de las variables visuales.*

La matriz de correlación (Figura 5) muestra cuatro relaciones relevantes:

- `green_ratio` – `brightness` (**r = +0.61**): la máscara de color detecta menos césped en frames oscuros, así que la cobertura de cancha depende de la iluminación.
- `green_ratio` – `contrast` (**r = −0.53**) y `green_ratio` – `edge_density` (**r = −0.47**): a más cancha visible, escena más limpia. `green_ratio` separa las tomas de juego abierto de las tomas cerradas.
- `contrast` – `edge_density` (**r = +0.44**): ambas miden el detalle de la escena.
- `player_count` por blobs casi no correlaciona con nada ($|r| \leq 0.20$), otra señal de que no mide jugadores.

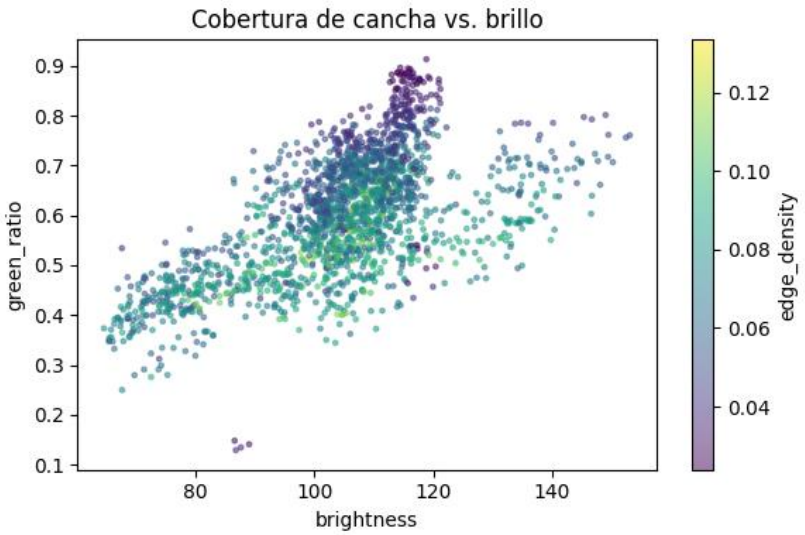


Figura 6. *Dispersión de cobertura de cancha frente a brillo, coloreada por densidad de bordes.*

El diagrama de dispersión (Figura 6) confirma la relación: los frames con brillo menor a 80 tienen poca cancha detectada y más bordes, y aparece un segundo grupo de frames muy brillantes (brillo > 125) con cobertura media: 114 de esos 124 frames provienen de solo dos partidos (`d82e7a` y `c01561`), es decir, de transmisiones con iluminación distinta.

5.3 Variables categóricas

Tabla 4. *Frecuencia y proporción de los tipos de evento en train.csv.*

Evento	Frecuencia	Proporción
play	3,586	32.0 %
start	3,418	30.5 %
end	3,418	30.5 %
challenge	624	5.6 %
throwin	172	1.5 %
total	11,218	100.0 %

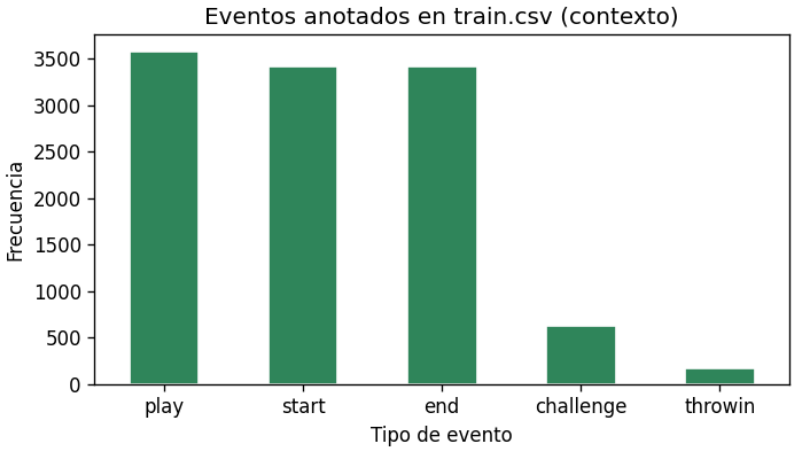


Figura 7. *Eventos anotados en train.csv.*

Las jugadas (`play`) son el evento más frecuente (32.0 %), seguidas de los marcadores `start` y `end` (30.5 % cada uno, Tabla 4). Las disputas (5.6 %) y los saques de banda (1.5 %) son minoritarios.

Tabla 5. *Tabla de contingencia de las jugadas: acción × contexto (frecuencia y proporción sobre las 3,586 jugadas).*

Contexto	pass	cross	Total
openplay	3,337 (93.1 %)	80 (2.2 %)	3,417 (95.3 %)
freekick	127 (3.5 %)	5 (0.1 %)	132 (3.7 %)
corner	4 (0.1 %)	33 (0.9 %)	37 (1.0 %)
total	3,468 (96.7 %)	118 (3.3 %)	3,586 (100 %)

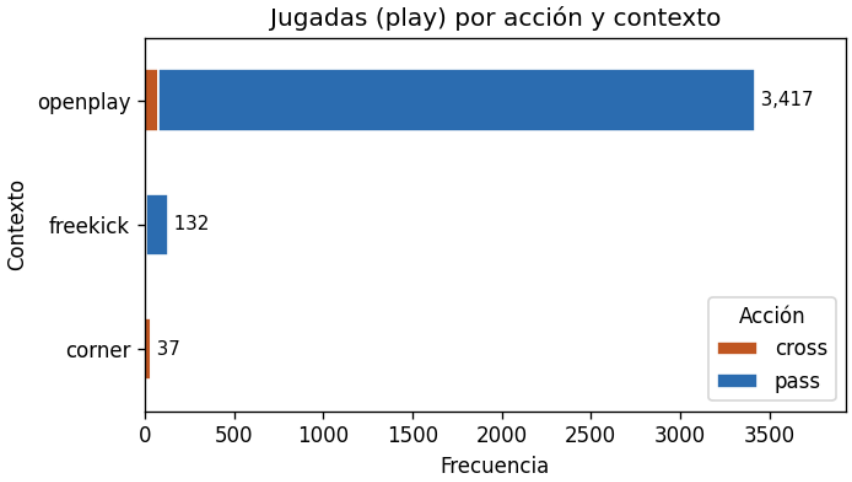


Figura 8. *Jugadas por acción (pase o centro) y contexto.*

Cada jugada lleva dos atributos: la acción (`pass` o `cross`) y el contexto (`openplay`, `freekick` o `corner`). La Tabla 5 los cruza: hay **3,468 pases** (96.7 %) y **118 centros** (3.3 %). Los pases son casi todos de juego abierto (3,337, el 93.1 % de las jugadas), con 127 de tiro libre y solo 4 de córner; los centros se reparten en 80 de juego abierto, 33 de córner y 5 de tiro libre. La distribución está **fuertemente desbalanceada**, algo que un modelo deberá compensar.

Tabla 6. *Frecuencia de los atributos de disputas (challenge) y saques de banda (throwin).*

Evento	Atributo	Frecuencia	Proporción
challenge	ball_action_forced	239	38.3 %
	opponent_dispossessed	138	22.1 %
	fouled	111	17.8 %
	challenge_during_ball_transfer	53	8.5 %
	possession_retained	44	7.1 %
	opponent_rounded	39	6.2 %
throwin	pass	154	89.5 %
	cross	18	10.5 %

Las disputas se describen por su resultado; la más común es `ball_action_forced` (38.3 %). Los saques de banda son en su mayoría pases (89.5 %) frente a centros (10.5 %) (Tabla 6).

En los clips, la variable categórica principal es el partido (`match_id`). La muestra está balanceada: cada uno de los 20 partidos aporta 100 frames (5 %). Sin embargo, la cobertura de

cancha **varía mucho entre partidos** (Figura 9): su mediana va de 0.42 (`0a2d9b`) a 0.81 (`e624c9`), y entre partidos correlaciona con el brillo medio (r = 0.62). Un umbral de color fijo no servirá para todos los estadios: habrá que normalizar por partido o usar umbrales adaptativos.

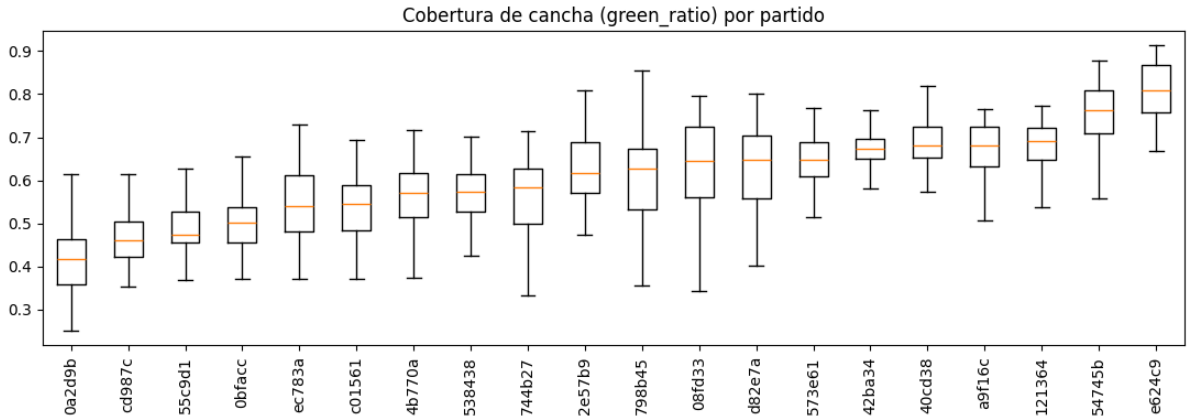


Figura 9. *Cobertura de cancha (green_ratio) por partido, ordenada por mediana.*

5.4 Detección de jugadores y separación de equipos

Tabla 7. *Jugadores por frame: YOLOv8n frente al proxy por blobs en los mismos 600 frames.*

Método	Media	Desv.	Mín.	Mediana	Máx.
YOLOv8n	11.9	4.3	0	12	23
Blobs	61.9	21.8	24	60	155

Con un detector YOLOv8n preentrenado (clase persona de COCO) se analizaron 3 frames por clip. Se detectan en promedio **11.9 jugadores por frame** (mediana 12, máximo 23, un solo frame sin detecciones), coherente con el plano táctico. En los mismos frames, el proxy por blobs reporta ≈62 y su correlación con YOLO es **r = −0.04** (Tabla 7): cuenta ruido de gradas y líneas. Por partido, la media va de 8.5 a 14.5 jugadores según el encuadre de cada transmisión.

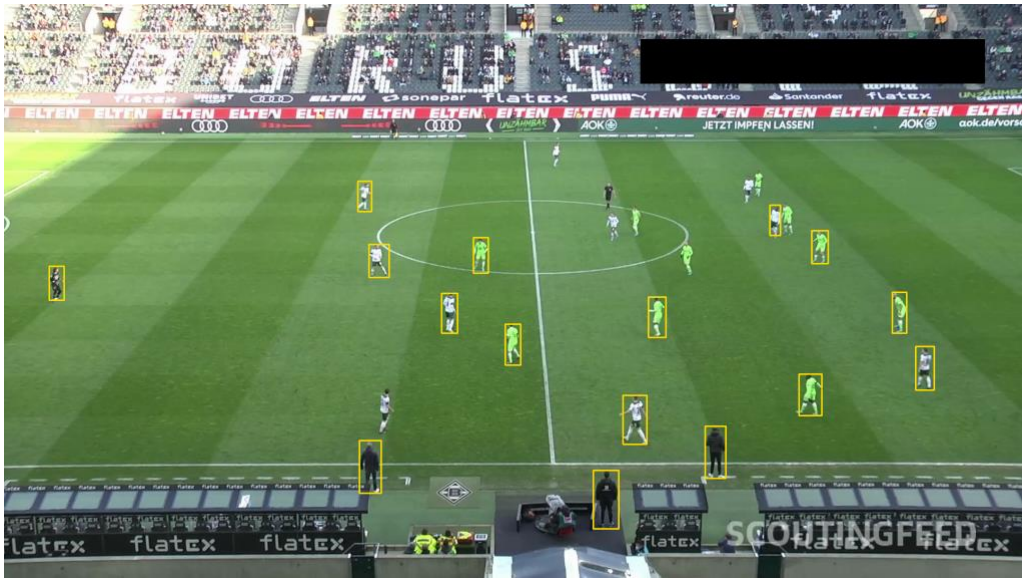


Figura 10. *Ejemplo de detección de jugadores con YOLOv8n.*

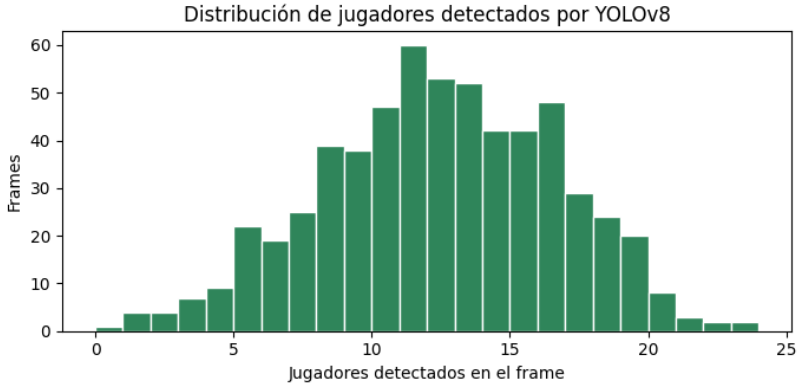


Figura 11. *Distribución de jugadores detectados por frame.*

Para cada jugador detectado se tomó el color HSV medio del torso (7,168 detecciones). Al juntar los 20 partidos, el matiz forma una distribución casi unimodal alrededor de H ≈ 40 (Figura 12): cada partido tiene uniformes distintos y el recorte incluye algo de césped, por lo que la separación en equipos debe hacerse **dentro de cada partido**. Se aplicó k-means (k = 2) sobre matiz circular, saturación y valor, y se midió la calidad con el coeficiente silhouette.

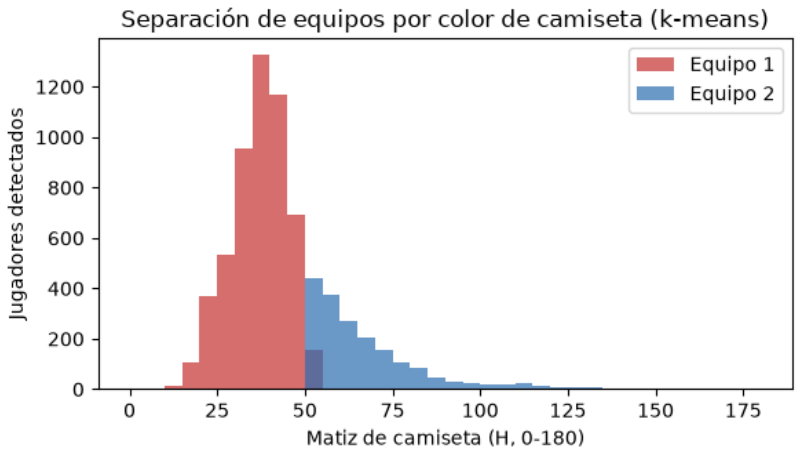


Figura 12. *Matiz de camiseta de todas las detecciones, agrupado con k-means.*

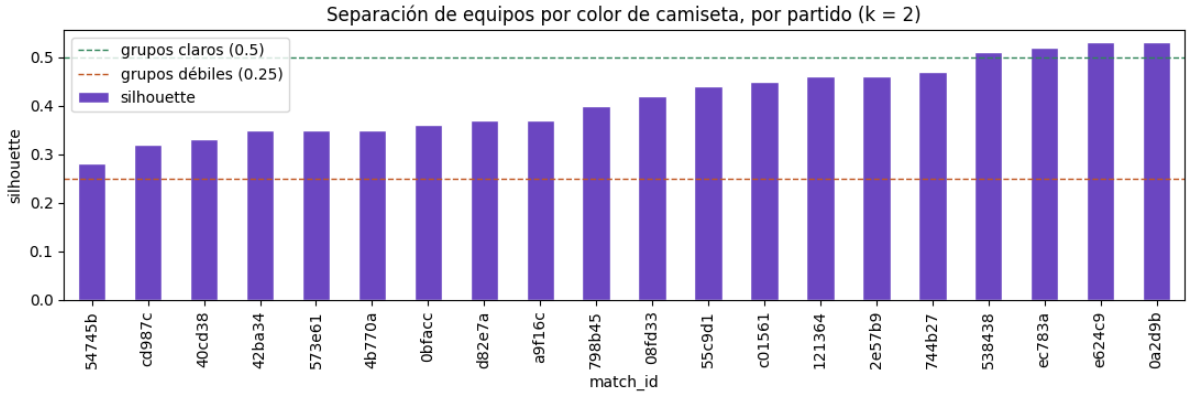


Figura 13. *Silhouette de la separación en dos equipos por partido.*

El silhouette medio es **0.41** (de 0.28 a 0.54, Figura 13): la separación es **moderada**, con grupos de tamaño parecido (en casi todos los partidos el menor reúne entre 30 % y 50 % de los jugadores), como se espera de dos equipos. El color es una señal útil para asignar cada jugador a su equipo, pero no suficiente por sí sola: árbitros, porteros y el césped dentro del recorte introducen ruido.

5.5 Movimiento y contexto temporal

La variable `motion` (diferencia absoluta media en gris entre dos frames muestreados consecutivos, separados ≈3 s) tiene media 24.1 y desviación 7.0 en los 1,800 frames válidos, con 29 outliers altos que tienen menos cancha visible (mediana de `green_ratio` 0.50 frente a 0.61), compatibles con cambios de plano. Correlaciona con el contraste (r = +0.39) y los bordes (r = +0.30), y negativamente con la cobertura de cancha (r = −0.31): con esta separación entre frames mide cambios de escena más que la trayectoria del balón.

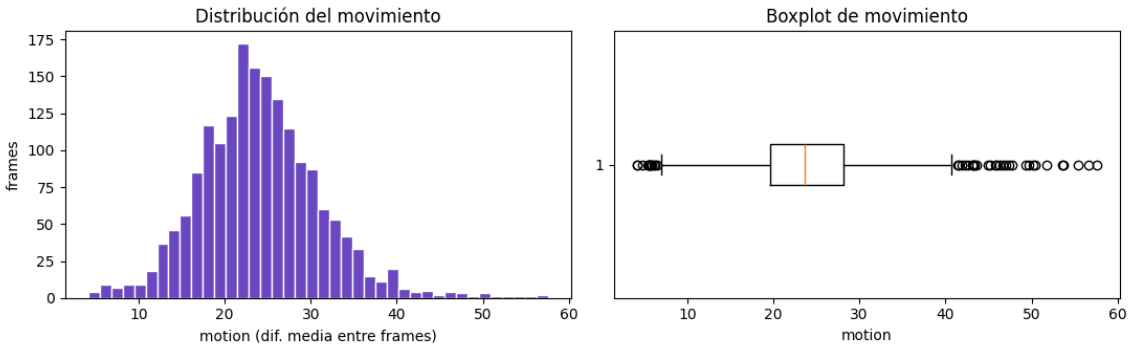


Figura 14. *Distribución y diagrama de caja del movimiento entre frames muestreados.*

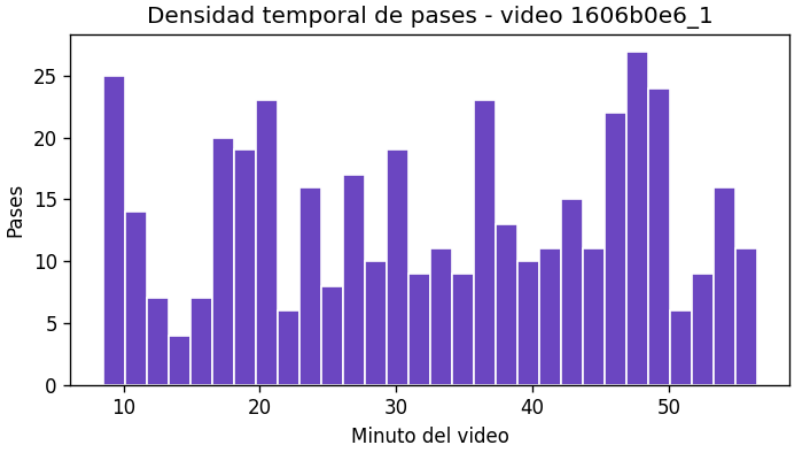


Figura 15. *Densidad temporal de pases en el video con más pases de train.csv.*

En `train.csv`, los pases se reparten a lo largo de todo el tiempo de juego con densidad variable (Figura 15). El tiempo entre pases consecutivos tiene mediana **4.1 s** y media 9.9 s (Figura 16): la media es mayor por las pausas del juego. Un detector necesita resolución de pocos frames, que los 25 fps de los clips permiten.

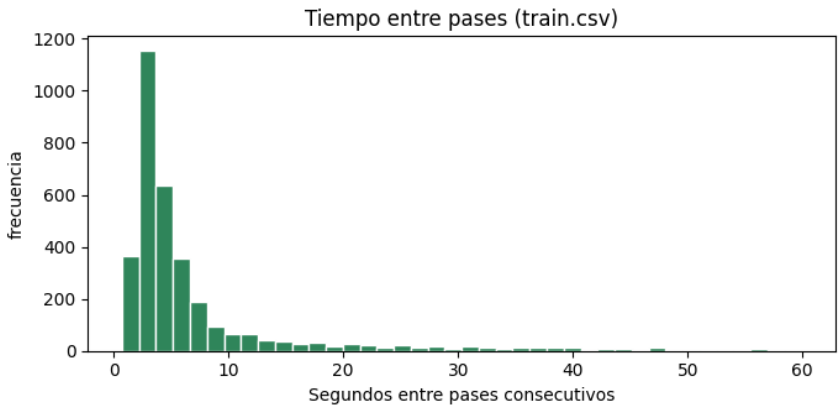


Figura 16. *Tiempo entre pases consecutivos en train.csv (menos de 60 s).*

6. Hallazgos y conclusiones

6.1 Hallazgos

- **Datos homogéneos y de calidad:** 200 clips a 1080p, 25 fps y 30 s, sin faltantes ni duplicados. Los únicos faltantes son estructurales (`start`/`end` y el primer `motion` de cada clip).
- **La cancha se aísla por color, pero depende del partido:** `green_ratio` separa el juego abierto de las tomas cerradas (r = −0.47 con bordes), aunque su mediana varía de 0.42 a 0.81 entre partidos y depende del brillo (r = +0.61).
- **Los jugadores son detectables con YOLO** (11.9 por frame); el proxy clásico por blobs no sirve (r = −0.04 con YOLO).
- **Los equipos son separables por color de forma moderada** dentro de cada partido (silhouette medio 0.41).
- **El movimiento entre frames separados ≈3 s refleja cambios de plano**, no el balón: para pases se necesitan frames sucesivos.
- **Los pases son frecuentes y desbalanceados:** 3,468 pases frente a 118 centros; el 93.1 % de las jugadas son pases de juego abierto, con una mediana de 4.1 s entre pases.

Retos identificados: el balón es pequeño y rápido y no está entre las detecciones analizadas; hay marca de agua y marcador superpuestos en todos los clips; la iluminación y el encuadre cambian entre partidos; existe desbalance de tipos de pase y los clips descargables no tienen etiquetas.

6.2 Cumplimiento de los objetivos

Tabla 8. *Resultado medido para cada objetivo específico.*

Objetivo	Resultado
1. Formato de los clips	200/200 legibles; 0 desviaciones de 1920×1080, 25 fps y 30 s.
2. Eventos de train.csv	Frecuencias y proporciones de 5 eventos y 6 combinaciones acción × contexto; mediana de 4.1 s entre pases.
3. Señales visuales	2,000 frames: estadística descriptiva, outliers IQR y correlaciones (Tablas 2–3, Figuras 3–6).
4. Jugadores y equipos	600 frames: 11.9 jugadores por frame; silhouette medio 0.41 por partido.

6.3 Conclusiones y siguientes pasos

El dataset es **viable** para un sistema de detección de pases por visión: los videos son homogéneos, la cancha y los jugadores se detectan con herramientas estándar y los equipos pueden separarse por color. Los siguientes pasos son:

- **Filtrar tomas no útiles** con un umbral de `green_ratio` normalizado por partido.
- **Detectar el balón** reentrenando YOLO con esa clase y **seguir** jugadores y balón entre frames sucesivos (tracking).
- **Asignar equipo** por color dentro de cada partido, segmentando la camiseta para quitar el césped del recorte.
- **Clasificar la acción** con un modelo temporal sobre ventanas de frames, usando los picos de movimiento entre frames sucesivos como candidatos.

- **Obtener etiquetas:** usar los videos anotados de `train.csv` o etiquetar una muestra de los clips, y evaluar con métricas por clase (F1 y precisión promedio con tolerancia temporal), sobre-muestreando las jugadas a balón parado por el desbalance.

Referencias

DFL – Bundesliga Data Shootout. Kaggle, 2022. https://www.kaggle.com/competitions/dfl-bundesliga-data-shootout

dbal0503/Bundesliga. Hugging Face Datasets. https://huggingface.co/datasets/dbal0503/Bundesliga

Jocher, G., Chaurasia, A. y Qiu, J. Ultralytics YOLOv8, 2023. https://github.com/ultralytics/ultralytics

Giancola, S. et al. SoccerNet: A Scalable Dataset for Action Spotting in Soccer Videos. CVPR Workshops, 2018.